浙江工業大學

# 本科生毕业论文（设计）
# 开题报告

题目：基于统计学习与特征工程的客户流失预测与归因分析


学　　院：数学科学学院

专　　业：数据科学与大数据技术

班　　级：数据科学与大数据技术 2201

学　　号：202205620114

学生姓名：林诣

指导老师：周凯


提交日期：2026/3

# 基于统计学习与特征工程的客户流失预测与归因分析

## 一、立题背景及意义

伴随着数字经济的渗透与移动互联网的全面普及，近年来，电信行业已经从增量市场逐步演化为存量竞争市场。根据工业和信息化部数据，我国移动电话用户总数现已达 18.27 亿[1]，市场饱和度持续攀升，各大运营商的新增用户红利几乎耗尽。在此背景下，如何降低现有客户的流失率、提升客户生命周期价值（Customer Lifetime Value, CLTV）,已逐步成为电信业维持行业竞争优势、保障长期收益率和盈利能力的战略核心。

学术研究与产业实践均已证明，获取一名新客户的综合成本是留存一名老客户的五到七倍，而忠实客户在营收上的贡献往往是普通客户的数倍以上（Reichheld & Sasser, 1990）[2]。因此，对高价值客户流失风险的精准预测，不仅具有重要的经营管理意义，更在降本增效层面具有直接的经济价值。早期的客户流失研究多依赖于逻辑回归、决策树等传统统计学习方法，以盛昭瀚、柳炳祥（2005）[3]及桂现才等（2005）[4]为代表的国内学者较早将决策树模型引入电信客户流失分析，取得了一定成效，但在高维非线性特征的处理能力与类别不平衡问题上存在明显局限。

进入深度学习时代，基于神经网络的客户流失预测方法开始受到广泛关注。Saha 等（2023）[5]提出融合深度学习与集成方法的电信流失预测框架，展示了相比传统方法的显著性能优势。Wong 等（2020）[6]提出的基于堆叠降噪自编码器（Stacked Denoising Autoencoder，SDAE）的代价敏感集成学习框架，在处理样本不平衡与代价非对称问题上提供了新思路，本研究的核心方法直接受此启发。Chen 等（2025）[7]则从更宏观的视角系统综述了机器学习在电信流失预测领域的最新进展，指出特征工程与可解释性仍是制约实际部署的主要瓶颈。

在特征工程层面，如何从原始数据中挖掘具有判别力的潜在表示，是提升模型泛化能力的关键。基于 Boruta 算法的鲁棒特征选择（Kursa & Rudnicki, 2010）[8]通过构造影子特征并结合随机森林进行迭代显著性检验，相比单次重要性排序具有更强的稳健性，被广泛应用于高维生物信息与金融信用评估场景。与此同时，SDAE 通过随机掩蔽（masking corruption）的自监督预训练机制，能够在无监督条件下学习数据的鲁棒内部表示，已被证明可以有效弥补原始特征中稀疏性与弱非线性带来的信息损失。

在类别不平衡问题的处理上，电信客户流失场景中，流失用户通常仅占全体客户的 15%至 25%，构成典型的类别不平衡分类任务。仅依赖数据层面的过采样方法（如 SMOTE）可能引入噪声或造成过拟合，而纯算法层面的代价敏感学习虽可调整误分类惩罚权重，但对样本分布改变的适应能力有限。Shaikhsurab 等（2024）[9]采用自适应集成学习方法有效缓解了这一问题，但未充分结合深度特征表示。本研究将两类方法有机融合，以期在实际工业场景中实现更优的少数类（流失用户）识别能力。

在模型可解释性层面，随着监管合规要求与业务决策需求的双重驱动，黑盒模型的事后解释已成为学术与产业界的共同关注点。Madsen 等（2023）[10]对神经网络后验可解释性方法进行了系统综述，指出 SHAP（SHapley Additive exPlanations）[15]因其理论完备性与实用性在众多归因方法中脱颖而出。然而，SHAP 的可靠性本身也存在争议：其输出依赖模型的局部线性近似，对具有强非线性或高阶交互效应的模型可能产生误导性解释。因此，本研究进一步引入基于梯度的反事实解释方法（HotFlip/SEA）[12]，通过验证 SHAP 高重要性特征是否确为最小代价下驱动预测翻转的关键因素，从侧面检验 SHAP 解释的忠实性，形成“定位-验证”双层可解释性分析框架。

综上所述，本研究以 IBM Telco Customer Churn 公开数据集为实验基础，围绕“如何在兼顾预测精度与模型可解释性的前提下，有效应对电信客户流失预测中的特征稀疏性、样本不平衡与代价非对称”这一核心问题，系统性地融合 Boruta 特征选择、SDAE 深度表示学习、SMOTE-Bagging 集成均衡策略与代价敏感损失函数，并通过 SHAP 结合反事实验证构建可解释性评估体系，具有较强的理论创新意义与工程实践价值。

## 二、研究内容与研究方法

### （一）数据收集与预处理

本研究使用 IBM Telco Customer Churn 数据集，该数据集包含 7043 条客户记录与 21 个特征字段，涵盖客户基本人口统计信息（性别、年龄段、是否有配偶及家属）、服务订阅信息（电话、互联网、流媒体、增值服务等）、合同与账单信息（合同类型、支付方式、月费与总费用）以及目标变量（是否在本季度内流失）和扩展标注字段（流失原因、CLTV、流失评分）。

预处理流程主要包括以下环节：其一，缺失值分析与处理，借助 missingno 等工具可视化缺失分布，应用 Little’s MCAR 检验判断缺失机制，在符合随机缺失假设的前提下采用迭代式贝叶斯岭回归（IterativeImputer with BayesianRidge）进行填补，收敛容差设置为 0.00001；其二，异常值检

测，综合使用 Z-score 与 IQR 方法识别极端值，结合业务逻辑区分数据错误与真实极端情况，对后者采用鲁棒缩放（RobustScaler）以降低其影响；其三，特征编码与标准化，对类别型特征进行 One-Hot 编码，对数值型特征先进行异常值处理后再行标准化，对时间型特征进行归一化，标准化时机设置在特征工程完成之后、模型训练之前。值得注意的是，本数据集在初步探索后确认无系统性缺失，但上述流程的完整部署对方法可复现性具有重要意义。

（二）特征工程

特征工程分为特征构造与特征选择两个阶段。在特征构造阶段，结合电信行业领域知识和数据集字段特性，构造若干具有业务意义的复合特征，包括：基于在网时长（Tenure）与月费（Monthly Charge）的消费效率特征、基于服务订阅数量的综合服务利用率特征、以及基于合同类型与支付方式的客户粘性特征组合。

在特征选择阶段，采用 Boruta 算法进行鲁棒特征筛选。具体步骤为：首先对原始特征进行随机打乱生成同分布的“影子特征”（Shadow Features）；随后在包含原始特征与影子特征的扩展数据集上迭代训练随机森林，比较各原始特征的重要性是否显著优于同轮影子特征的最大值；通过多次迭代进行双侧二项检验，确认或拒绝各特征的显著性。相较于单次特征重要性排序，Boruta 通过多次随机化降低偶然误差，提供更稳健的特征选择结果，最终保留通过检验的显著特征进入后续建模流程。

基于 SDAE 的深度特征表示学习作为特征增强手段，通过对输入特征施加随机掩蔽噪声（Masking Noise）训练自编码器进行“完形填空式”重构，迫使网络学习特征间鲁棒的潜在依赖关系。训练完成后，将编码器各隐藏层的输出提取为高阶抽象表示，与 Boruta 选出的原始显著特征拼接，共同构成最终的建模特征空间，丰富特征信息量并增强对非线性关系的捕捉能力。

（三）数据集划分与类别均衡处理

数据集按 8:2 比例分层划分为训练集与测试集，分层依据目标变量（是否流失）分布，保证各子集中流失比例与原始数据集一致。训练集内部进一步划分出验证集用于超参数调优，最终划分方案视具体调参需求确定。

针对类别不平衡问题（流失用户约占全体的 26%），采用数据层面与算法层面相结合的双重应对策略。在数据层面，仅在训练集上应用 SMOTE 过采样方法，沿少数类近邻样本连线方向进行线性插值，扩充流失用户样本量，测试集保持原始真实分布以确保评估客观性。在算法层面，引入 Bagging 集成框架，从多数类（留存用户）中随机抽取多个子集，每个子集与全部少数类（流失用户）组合形成类别均衡的子训练集，在每个子集上独立训练代价敏感的深度神

经网络，最终以投票方式集成预测结果。这一策略既避免了欠采样造成的信息损失，又通过集成提升了对少数类的敏感度。

（四）模型构建

本研究的核心模型为基于 SDAE 的代价敏感 Bagging 集成分类器。分类层由全连接神经网络构成，在 SDAE 预训练特征表示的基础上进行端到端微调，损失函数采用加权交叉熵：

$$Loss = w_0 \times BCE(y=0) + w_1 \times BCE(y=1)，其中 w_1 >> w_0$$

权重 $w_1$ 的取值可参考用户终身价值（CLTV）字段，对高价值流失用户施加更高的误分类惩罚，使模型在保证整体性能的前提下，最大化对流失用户的识别召回率。

作为对照，本研究同时构建以下基准模型进行消融实验与性能比较：标准 DNN（无降噪、无代价敏感）、SMOTE+DNN、随机森林（Random Forest）、XGBoost、LightGBM 以及 AdaBoost。综合比较各模型在测试集上的准确率、召回率、F1-Score 与 AUC-ROC 指标，重点关注流失类的召回率与 F1 指标。

（五）可解释性与归因分析

首先应用 SHAP 方法对最优模型进行全局与局部的特征归因分析，生成特征重要性排序、Summary Plot 与单样本 Force Plot 等可视化结果，识别影响客户流失预测的关键驱动因素。

考虑到 SHAP 解释对复杂非线性模型存在潜在可靠性问题，本研究进一步引入反事实解释方法对 SHAP 结果进行验证。具体而言，基于梯度（HotFlip 思路）或充分解释子集（SEA 思路），在 SHAP 标记的高重要性特征上施加最小扰动，观察预测结果是否随之发生翻转。若高度一致，则从侧面验证了 SHAP 解释的忠实性；若出现不一致，则进一步分析特征交互效应与模型非线性结构对解释差异的贡献，形成“SHAP 定位-反事实验证”双层归因分析体系。

## 三、预期结果

（1）技术性能指标：在 IBM Telco Customer Churn 测试集上，预期最优模型的 AUC-ROC 达到 0.85 以上，F1-Score 达到 0.78 以上，流失类 Recall 达到 0.80 以上，相较于逻辑回归、标准 DNN 等基线方法具有显著提升。

（2）消融实验：系统验证 Boruta 特征选择、SDAE 特征表示、SMOTE 数据增强、Bagging 集成均衡以及代价敏感损失函数各组件的独立贡献，量化各模块的边际性能增益，论证整体框架设计的合理性。

（3）可解释性报告：基于 SHAP 全局分析，输出影响客户流失的 Top-10 关键特征排序及其业务解读；基于反事实验证结果，评估 SHAP 解释的忠实度，提炼可操作的客户留存干预建议。

（4）成果形式：完成不少于 1 万字的毕业论文，涵盖文献综述、数据分析、模型构建、实验对比与归因分析；提交完整 Python 代码及实验报告；提供 SHAP 特征重要性可视化分析报告。

## 四、课题计划进度

**表 4-1　课题计划进度表**

**Table 4-1　Project Schedule**

| 时间 | 任务 |
|---|---|
| 2026.02.15-2026.02.28 | 广泛阅读客户流失预测相关文献，梳理研究脉络，完成文献综述初稿。 |
| 2026.03.01-2026.03.20 | 收集电信客户流失公开数据集，完成数据预处理与探索性分析，制定特征工程方案。 |
| 2026.03.21-2026.04.15 | 构建并调优预测模型（逻辑回归、随机森林、XGBoost 等），进行模型对比实验与性能评估。 |
| 2026.04.16-2026.05.10 | 引入 SHAP 等可解释性方法进行归因分析，撰写论文初稿。 |
| 2026.05.11-2026.05.31 | 论文修改完善，整理代码与实验报告，准备答辩材料，完成论文定稿与提交。 |

# 参考文献


[1] 工业和信息化部. (2026, 1 月). 2025 年通信业统计公报解读：通信业运行平稳 新动能加快培育. https://www.miit.gov.cn/jgsj/yxj/xxfb/art/2026/art_ba84699fb1bc4341af494442525ad142.html

[2] Madsen, Andreas, Siva Reddy, and Sarath Chandar. "Post-Hoc Interpretability for Neural NLP: A Survey." *ACM Computing Surveys* 55, no. 8 (2023): 1–42. https://doi.org/10.1145/3546577.

[3] 盛昭瀚,柳炳祥.客户流失危机分析的决策树方法[J].管理科学学报,2005,(02):20-25.

[4] 桂现才,彭宏,王小华.C4.5 算法在保险客户流失分析中的应用[J].计算机工程与应用,2005,(17):197-199+214.

[5] 张宇,张之明.一种基于 C5.0 决策树的客户流失预测模型研究[J].统计与信息论坛,2015,30(01):89-94.

[6] 李爱民.基于逻辑回归和聚类分析的广电客户流失预警[J].信息与电脑(理论版),2016,(09):29-30+35.

[7] Saha, Lewlisa, Hrudaya Kumar Tripathy, Tarek Gaber, Hatem El-Gohary, and El-Sayed M. El-kenawy. "Deep Churn Prediction Method for Telecommunication Industry." *Sustainability* 15, no. 5 (2023): 4543. https://doi.org/10.3390/su15054543.

[8] Shaikhsurab, Mohammed Affan, and Pramod Magadum. "Enhancing Customer Churn Prediction in Telecommunications: An Adaptive Ensemble Learning Approach." arXiv:2408.16284. Preprint, arXiv, August 29, 2024. https://doi.org/10.48550/arXiv.2408.16284.

[9] Wong, Man Leung, Kruy Seng, and Pak Kan Wong. "Cost-Sensitive Ensemble of Stacked Denoising Autoencoders for Class Imbalance Problems in Business Domain." *Expert Systems with Applications* 141 (March 2020): 112918. https://doi.org/10.1016/j.eswa.2019.112918.

[10] Chen, Xuhang, Bo Lv, Mengqian Wang, et al. "A Comprehensive Analysis of Churn Prediction in Telecommunications Using Machine Learning." arXiv:2509.22654. Preprint, arXiv, July 15, 2025. https://doi.org/10.48550/arXiv.2509.22654.

[11] Idé, Tsuyoshi, and Naoki Abe. "Black-Box Anomaly Attribution." arXiv:2305.18440. Preprint, arXiv, August 17, 2024. https://doi.org/10.48550/arXiv.2305.18440.

[12] Chen, Ruoyu, Siyuan Liang, Jingzhi Li, et al. "Less Is More: Efficient Black-Box Attribution via Minimal Interpretable Subset Selection." arXiv:2504.00470. Preprint, arXiv, April 1, 2025. https://doi.org/10.48550/arXiv.2504.00470.

[13] Kursa, M. B., & Rudnicki, W. R. Feature Selection with the Boruta Package. Journal of Statistical Software, 36(11), 1-13. 2010.
[14] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research, 16, 321-357. 2002.
[15] 夏国恩,金炜东.基于支持向量机的客户流失预测模型[J].系统工程理论与实践,2008,(01):71-77.
[16] 丁君美,刘贵全,李慧.改进随机森林算法在电信业客户流失预测中的应用[J].模式识别与人工智能,2015,28(11):1041-1049.DOI:10.16451/j.cnki.issn1003-6059.201511010.
[17] 钱苏丽,何建敏,王纯麟.基于改进支持向量机的电信客户流失预测模型[J].管理科学,2007,(01):54-58.
[18] 应维云,覃正,赵宇,等.SVM 方法及其在客户流失预测中的应用研究[J].系统工程理论与实践,2007,(07):105-110.
[19] 王重仁,韩冬梅.基于社交网络分析和 XGBoost 算法的互联网客户流失预测研究[J].微型机与应用,2017,36(23):58-61.DOI:10.19358/j.issn.1674-7720.2017.23.017.

# 指导老师意见

导师需明确是否能开题

要求：中文宋体小四号、英文 Times New Roman 小四号，1.25 倍行距，段前段后各 0 磅，两端对齐，首行缩进 2 字符

指导教师（签名）：

年　　月　　日