浙江工業大學

本科生毕业论文（设计）
文献综述

题目：基于统计学习与特征工程的客户流失预测与归因分析

学　　院：数学科学学院

专　　业：数据科学与大数据技术

班　　级：数据科学与大数据技术 2201

学　　号：202205620114

学生姓名：林诣

指导老师：周凯

提交日期：2026/3

基于统计学习与特征工程的客户流失预测与归因分析

一、文献综述

数字经济时代下，通信行业已经逐步成为推动技术创新与国际业务拓展的核心驱动力。然而，随着市场的日趋饱和与竞争白热化，电信运营商目前面临前所未有的挑战：价格战持续升级、消费者需求快速迭代、技术更新周期缩短。在此背景下，客户留存需求逐步超越客户获取需求：对于长期业务运营，在客户关系管理方面努力提高少数新客户的获取不如努力进行广泛性的客户保留活动有效，这也逐步成为各大电信运营商的共识和维持企业竞争优势的战略重点。因此，精准识别客户画像、科学评估客户终身价值（Customer Lifetime Value, CLV）、有效预测客户流失（Customer Churn Prediction，CCP）已成为学术界与产业界共同关注的核心议题。

相关客户流失预测研究可追溯至 20 世纪 90 年代，经过近四十年的理论积累与实践探索，该领域已然形成较为完善的研究体系。纵观相关文献并进行归纳整理可以发现，客户流失预测本质上是一个二分类问题，其核心在于通过分析客户行为特征、消费模式以及交互数据，构建能够步骤流失信号的预测模型。根据研究方法的演替脉络与模型复杂度的提升，本文将该领域的发展划分为三个阶段：传统统计学习阶段、深度学习与集成学习阶段、可解释性与代价敏感学习阶段。

第一阶段：传统统计学习方法时期（1990s-2010s）

早期的客户流失预测研究主要依赖传统统计学习方法，代表性模型包括决策树（Decision Tree）、逻辑回归（Logistic Regression）、贝叶斯网络（Bayesian Network）以及基于聚类的分析方法。这一阶段的研究强调特征工程的重要性，研究者通过相关性分析、因子分析、主成分分析（PCA）等技术筛选显著特征，利用卡方检验、t 检验等统计推断方法验证特征的有效性。

盛昭瀚等人（2005）[2]针对传统 ID3 算法倾向于选择多值属性的偏倚问题，创造性地引入“加权熵”概念，提出了一种兼顾信息增益与分枝权重的改进决策树方法。桂现才等人（2005）[3]将 C4.5 算法应用于保险业，通过属性导向归纳技术，识别出资产总额与特定业务频次是影响流失的关键变量，验证了该方法在金融领域的适用性。张宇等人（2015）[4] 则在邮政业务场景下，利用结合 Boosting 技术的 C5.0 算法挖掘出具体的流失规则，揭示了“合同期满一年”及“20-39 岁”为高风险特征，同时证实了服务年限与客户忠诚度的正相关性。此外，李爱民（2016）[5]尝试采用 K-means 聚类结合逻辑回归的混合策略，尽管在正样本识别上表现优异，但其对流失客户极低的召回率（40.99%）深刻揭示了传统统计学习

方法在处理非平衡数据集时的内在局限性。

此类方法在数学上较为完备同时理论基础扎实、模型结果具有较强的可解释性，能够清晰地呈现特征与流失概率之间的因果关系或关联模式。然而,传统统计方法存在明显的局限性：

1. 分布假设的严格性：多数统计方法（如线性回归、判别分析）要求数据满足正态性、方差齐性等前提条件，而客户流失数据往往呈现显著的偏态分布与类别不平衡特征（流失客户通常占比不足 10%-20%）。
2. 非线性关系的捕捉能力不足：客户流失行为受多维因素交互影响，特征间存在复杂的非线性关系，传统线性模型难以有效建模这种复杂性。
3. 高维数据处理的挑战：随着数据采集技术的进步，客户特征维度急剧增加（包括通话记录、数据使用、缴费行为、服务投诉等），传统方法在高维稀疏数据上的泛化能力受限。
4. 时序依赖的忽视：客户行为具有明显的时间序列特性，而多数统计方法将数据视为独立同分布样本，未能充分利用时序信息。

这些局限性制约了传统统计方法在实际应用中的预测精度与稳健性。

第二阶段:深度学习与集成学习时期（2010s-2020s）

为克服传统方法的不足，研究者开始引入更为强大的机器学习与深度学习技术，包括人工神经网络（Artificial Neural Network, ANN）、支持向量机（Support Vector Machine, SVM）、随机森林（Random Forest）以及基于 Boosting 的集成算法（如 AdaBoost、XGBoost、LightGBM、CatBoost 等）。

在电信客户流失预测领域，Saha 等人（2023）[6] 通过严格的 ANOVA 和 Wilcoxon 统计检验，证实了卷积神经网络（CNN）相较于随机森林、XGBoost 等传统机器学习算法具有统计学上的显著性能优势。Shaikhsurab 等人（2024）[7] 则提出了一种自适应堆叠集成框架，通过融合 LSTM、LightGBM 等异构模型并引入元特征生成技术，验证了集成策略在捕捉数据一致性与差异性模式方面优于单一模型，在多个数据集上实现了极高的预测精度。Chen 等人（2025）[9]提出了一个综合性的电信客户流失预测框架,采用专门设计的深度神经网络架构。数据集呈现类别不平衡,流失客户约占 26.5%。研究对比了多种基线方法包括逻辑回归（准确率 73.18%）、随机梯度下降（71.94%）、决策树（74.41%）和随机森林（72.70%）,所提方法在 Telco 客户流失数据集上取得最优性能:准确率达到 82.26%,F1 分数为 82.09%,精确率 81.96%,召回率 82.26%,全面超越所有对比方法。

这一阶段的研究呈现以下特点：

1. 自动化特征学习：深度神经网络通过多层非线性变换，能够自动提取数据的深层表征，减少了对人工特征工程的依赖。
2. 非线性关系建模：通过非线性激活函数（如 ReLU、Sigmoid、Tanh）与深

层网络结构，这些方法能够有效捕捉特征间的复杂交互与高阶关系。

3. 集成学习的鲁棒性提升：基于 Boosting 和 Bagging 的集成方法通过构建多样化的基学习器（特征子空间采样、样本子空间采样），显著提升了模型在类别不平衡数据上的泛化能力。
4. 端到端的优化框架：深度学习模型通过反向传播算法与梯度下降优化，实现了从原始输入到预测输出的端到端学习，避免了传统方法中特征提取与模型训练的割裂。

然而，随着这些"黑盒"模型在实际部署中的广泛应用，新的问题逐渐凸显：

1. 可解释性缺失：深度学习模型内部的决策逻辑难以理解，无法为业务人员提供可操作的洞察，这在金融、医疗等受监管行业尤为关键。
2. 类别不平衡的权衡不足：尽管集成方法在一定程度上缓解了类别不平衡问题,但在实际应用中，不同类型的预测错误（假阳性与假阴性）具有不同的业务代价，现有研究对此关注不足。
3. 代价敏感学习的需求：在客户流失场景中，"误判潜在流失客户为忠诚客户"（假阴性）的代价远高于"误判忠诚客户为流失客户"（假阳性），因此需要构建考虑不对称误分类代价的模型。

第三阶段：可解释性与代价敏感学习时期（2020s 至今）

针对第二阶段暴露的问题，近年来的研究聚焦于两个核心方向：模型事后可解释性（Post-hoc Interpretability）与代价敏感学习（Cost-Sensitive Learning）。

事后可解释性旨在通过外部分析工具揭示"黑盒"模型的决策机制，为流失预测模型的结果做归因分析，为实践提供可操作的洞察。从解释抽象度和解释机制选择的角度来看，可解释性方法可按照两个维度分类[1]：

按解释范围分类：

- 局部解释（Local Explanation）：针对单个样本的预测提供解释，包括：
  - 基于特征重要性的方法：如 SHAP、LIME、Gradient-based 方法等
  - 基于对抗样本的方法：如 SEA（Sensitivity Analysis）
  - 基于影响样本的方法：如 Influence Functions、Representer Points 等
  - 基于反事实的方法：如 Polyjuice、MiCE 等
  - 基于自然语言的方法：如 CAGE 等
- 全局解释（Global Explanation）：揭示模型的整体决策模式，包括：
  - 概念解释：如 NIE（Neural Interaction Effects）
  - 词汇表方法：如 Project、Rotate 等
  - 集成方法：如 SP-LIME
  - 规则提取：如 SEAR（Structured Explanation via Augmented Rules）

按解释方式分类：

- 事后方法（Post-hoc）：模型训练完成后应用，如上述大部分方法
- 内在方法（Intrinsic）：模型本身具备可解释性，如注意力机制（Attention）、原型网络（Prototype Networks）、GEF、NILE 等

Idé和 Abe（2024）[10]针对“双重黑盒”回归场景，揭示了 LIME 和 SHAP 等现有方法存在的“偏差不可知”缺陷，提出了似然补偿框架，通过寻找最大化似然的输入扰动来解释异常预测的成因。Chen 等人（2025）[11]则提出了名为 LIMA 的高效黑盒归因机制。该研究基于输入特征的“边际效应递减”现象，创新性地将归因任务重构为子模子集选择问题。通过结合语义一致性等四维约束的子模函数与双向贪婪搜索算法，LIMA 在 CLIP 等基础模型上实现了效率（提升 1.6 倍）与保真度（Insertion/Deletion 指标提升超 36%）的双重突破，尤其在解释模型预测错误方面，其定位的区域置信度比现有 SOTA 方法高出 86.1%。

与此同时，由于客户流失问题本身的特殊性，预测模型需要同时应对“将潜在流失客户误判为忠诚客户”（假阴性）与“将忠诚客户误判为流失客户”（假阳性）所带来的不同业务代价。因此，有必要引入代价敏感学习。代价敏感学习通过在目标函数中设置不对称的误分类代价，引导模型在优化预测性能的同时，更好地契合实际业务目标。其主要方法包括：

1. 代价矩阵法：显式定义不同误分类类型的代价权重。
2. 重采样技术：通过过采样少数类（如 SMOTE）或欠采样多数类调整或平衡训练集分布，使模型更关注流失客户。
3. 阈值移动：在模型预测概率的基础上，根据代价比例调整分类阈值。
4. 集成代价敏感算法：如 Cost-Sensitive XGBoost、MetaCost 等，将代价信息直接嵌入算法框架。

Wong 等人（2020）[8]提出的 CSDE 方法将集成学习与代价敏感深度神经网络相结合。该方法采用改进的 Bagging 策略。实验对比了 17 种方法,包括 AdaCost、MetaCost、RUSBoost、RBBoost、SMOTEBoost 等,结果显示 CSDE 在平均排名中位列第一,且泛化误差最小,证明该方法既不易过拟合,又能保持优异的泛化性能。

研究展望与总结

纵观客户流失预测研究的演进历程，每一阶段的方法创新均源于对前一阶段局限性的反思与突破：统计学习方法奠定了理论基础但受限于模型假设；深度学习与集成学习提升了预测性能但牺牲了可解释性；可解释性与代价敏感学习则致力于在性能与透明度、预测准确性与业务目标之间寻求平衡。

未来的研究可能聚焦于以下方向：

1. 发展内在可解释的深度模型。
2. 融合因果推断方法，从相关性分析转向因果关系挖掘。
3. 构建动态更新的在线学习框架，细粒度处理客户行为信息。

4. 结合多模态数据（文本、图像、语音）丰富客户画像维度。
5. 探索联邦学习等隐私保护技术，在保障数据安全的前提下提升模型性能。

参考文献

[1] Madsen, Andreas, Siva Reddy, and Sarath Chandar. “Post-Hoc Interpretability for Neural NLP: A Survey.” *ACM Computing Surveys* 55, no. 8 (2023): 1–42. https://doi.org/10.1145/3546577.

[2] 盛昭瀚,柳炳祥.客户流失危机分析的决策树方法[J].管理科学学报,2005,(02):20-25.

[3] 桂现才,彭宏,王小华.C4.5 算法在保险客户流失分析中的应用[J].计算机工程与应用,2005,(17):197-199+214.

[4] 张宇,张之明.一种基于 C5.0 决策树的客户流失预测模型研究[J].统计与信息论坛,2015,30(01):89-94.

[5] 李爱民.基于逻辑回归和聚类分析的广电客户流失预警[J].信息与电脑(理论版),2016,(09):29-30+35.

[6] Saha, Lewlisa, Hrudaya Kumar Tripathy, Tarek Gaber, Hatem El-Gohary, and El-Sayed M. El-kenawy. “Deep Churn Prediction Method for Telecommunication Industry.” *Sustainability* 15, no. 5 (2023): 4543. https://doi.org/10.3390/su15054543.

[7] Shaikhsurab, Mohammed Affan, and Pramod Magadum. “Enhancing Customer Churn Prediction in Telecommunications: An Adaptive Ensemble Learning Approach.” arXiv:2408.16284. Preprint, arXiv, August 29, 2024. https://doi.org/10.48550/arXiv.2408.16284.

[8] Wong, Man Leung, Kruy Seng, and Pak Kan Wong. “Cost-Sensitive Ensemble of Stacked Denoising Autoencoders for Class Imbalance Problems in Business Domain.” *Expert Systems with Applications* 141 (March 2020): 112918. https://doi.org/10.1016/j.eswa.2019.112918.

[9] Chen, Xuhang, Bo Lv, Mengqian Wang, et al. “A Comprehensive Analysis of Churn Prediction in Telecommunications Using Machine Learning.” arXiv:2509.22654. Preprint, arXiv, July 15, 2025. https://doi.org/10.48550/arXiv.2509.22654.

[10] Idé, Tsuyoshi, and Naoki Abe. “Black-Box Anomaly Attribution.” arXiv:2305.18440. Preprint, arXiv, August 17, 2024. https://doi.org/10.48550/arXiv.2305.18440.

[11] Chen, Ruoyu, Siyuan Liang, Jingzhi Li, et al. “Less Is More: Efficient Black-Box Attribution via Minimal Interpretable Subset Selection.” arXiv:2504.00470. Preprint, arXiv, April 1, 2025. https://doi.org/10.48550/arXiv.2504.00470.